

Credit Risk Prediction

Membangun model machine learning untuk memprediksi risiko gagal bayar pinjaman — menggunakan data 466 ribu peminjam dari Lending Club.



DATASET
Lending Club 2007–2014

TASK
Binary Classification

MODELS
LR · XGBoost · Stacking

AUTHOR
Jian Hazel Sitorus

Setiap pinjaman yang **gagal bayar** adalah kerugian langsung.

Lending company harus memutuskan untuk setiap calon peminjam — apakah mereka akan membayar kembali, sebelum uang berpindah tangan. Keputusan ini sebagian besar masih bergantung pada intuisi.

HIGH
RISK

False Negative

Meloloskan peminjam yang akan gagal bayar →
kerugian finansial langsung

TOLERABLE

False Positive

Menolak peminjam baik → opportunity cost, tapi
masih dapat ditoleransi

466,285 loan records across 8 years.

Dataset dari Lending Club (2007–2014). Setiap baris adalah satu pinjaman — siapa peminjamnya, syarat pinjaman, dan apakah dibayar kembali.

RAW RECORDS

466,285

75 columns

AFTER FILTERING

228,046

Fully Paid + Charged Off

BAD DEBT RATE

19.0%

imbalance $\approx$ 5 : 1

Class-imbalanced binary classification.

Status Current, Late, dan In Grace Period dibuang karena outcome belum diketahui. Sisanya diberi label Good Debt atau Bad Debt.

GOOD DEBT

184,739

Fully Paid · 81.0%

BAD DEBT

43,307


Charged Off + Default · 19.0%



Default rate by loan grade.


Setiap turun satu grade, default rate hampir berlipat ganda. Grade G gagal bayar 7x lebih sering dibanding Grade A.


N = 228,046 · DEFAULT RATE PER LC GRADE



Key features vs credit risk.

Boxplot menunjukkan distribusi fitur utama untuk Good Debt vs Bad Debt. Interest rate dan DTI secara konsisten lebih tinggi pada peminjam yang gagal bayar.





Multicollinearity check.

Korelasi tinggi antara loan_amnt dan installment (0.96) menandakan perlu hati-hati saat modeling. Interest rate berkorelasi moderat dengan beberapa fitur risiko lainnya.

- Korelasi positif kuat (≥ 0.8)
- Korelasi moderat (0.2 – 0.4)
- Korelasi negatif lemah

Empat pola utama dari eksplorasi data.

01

Interest Rate

Suku bunga berkorelasi kuat dengan default — peminjam berisiko membayar harga itu di muka.

$\text{corr} \approx +0.36$

02

Term Length

Pinjaman 60 bulan default 2_x lebih sering dibanding 36 bulan — waktu adalah eksposur risiko.

30.7% vs 15.4%

03

Delinquency History

Riwayat tunggakan adalah prediktor kuat — perilaku masa lalu cenderung berulang.

$\text{delinq_2yrs} > 0 \rightarrow +6\text{pp}$

04

Annual Income

Distribusi sangat right-skewed — outlier ekstrim perlu di-cap sebelum masuk ke model.

$\text{P99} = \$244\text{K} \cdot \text{max} = \7.5M

Dari 75 kolom mentah ke feature matrix.

Tiga lapis transformasi memisahkan sinyal dari noise — dan menambahkan 8 fitur baru yang menangkap perilaku finansial peminjam.

STEP 01 · CLEANING

Data Cleaning

Konversi int_rate dan revol_util dari string ke numerik. Mapping emp_length ke ordinal 0–10. Drop 40+ kolom leakage & identifier.

STEP 02 · FEATURE ENGINEERING

8 fitur baru

installment_to_income, loan_to_income, revol_utilization, total_debt_ratio, collection_flag, credit_history_months, dan lainnya.

STEP 03 · PREPROCESSING

Imputation, encoding, scaling

Median imputation (numerik), mode (kategorikal). Outlier capping via IQR. Label + One-Hot encoding. StandardScaler. Train/test split 80/20 stratified.

Tiga model, satu test set.

Saya membandingkan baseline yang interpretable, gradient boosting, dan ensemble dari ketiganya.

MODEL 01

Logistic Regression

Baseline — koefisiennya langsung bisa diinterpretasikan.

solver	saga
tuning	C, penalty
weights	balanced

MODEL 02

XGBoost

Gradient boosting — menangkap interaksi non-linear antar fitur.

scale_pos	tuned
reg α/λ	1/5
search	30 iter random

BEST

MODEL 03

Stacking Ensemble

Tiga base learner di-blend oleh meta-learner via probabilitas.

base	LR · XGB · RF
meta	Logistic Reg
cv	3-fold

SEMUA MODEL DIOPTIMASI VIA THRESHOLD TUNING PADA PRECISION-RECALL CURVE

Pada data 5 : 1, threshold 0.5 bukan jawaban.

Default threshold 0.5 membuat model terlalu konservatif — banyak Bad Debt lolos. Saya menurunkan threshold ke titik F1-score maksimum dari precision-recall curve.

BEFORE · THRESHOLD = 0.50

31%

RECALL

Hanya ≈ 3 dari 10 bad loan terdeteksi

AFTER · THRESHOLD = 0.31 (XGB)

61%

RECALL

≈ 6 dari 10 bad loan tertangkap — hampir 2 $\times$ lipat

Head-to-head pada test set.


n_test = 45,610 · F1-optimal threshold per model

MODEL	ACCURACY	PRECISION	RECALL	F1-SCORE	ROC-AUC	OVERFIT Δ
Logistic Regression	0.663	0.309	0.628	0.415	0.704	0.001
★ XGBoost	0.686	0.325	0.605	0.422	0.714	0.028
Stacking Ensemble	0.677	0.320	0.622	0.422	0.714	0.024

★ BEST · XGBOOST


Semua model dengan overfit gap < 0.05 — generalisasi baik.

ROC Curve



— LR 0.704 — **XGB 0.714** — Stack 0.714


Confusion Matrix (after tuning)



5 dari 8 fitur teratas adalah hasil feature engineering.

Feature engineering bukan hanya langkah teknis — fitur buatan saya seperti installment_to_income dan total_debt_ratio naik ke puncak pentingnya.

XGBOOST · TOP 8 BY FEATURE IMPORTANCE · ★ = ENGINEERED



Deploy XGBoost sebagai **decision-support layer** — bukan verdict.

IMPLEMENTASI SEKARANG

- Deploy dengan threshold yang sudah dioptimasi (F1-max).
- Sebagai decision support tool, bukan pengganti underwriter.
- Monitor false negative berkala; retrain setiap kuartal.

LANGKAH SELANJUTNYA

- ➡ Tambahkan credit bureau score & data eksternal — target AUC > 0.75.
- ➡ Behavioral data (post-origination) untuk model jangka panjang.
- ➡ A/B test pada subset peminjam sebelum full deployment.

0.714 ROC-AUC

0.422 F1-Score

60.5% Recall

0.028 Overfit gap

— END

CREDIT RISK PREDICTION · ID/X PARTNERS · 2026

Thank you.

AUTHOR
Jian Hazel Sitorus

ROLE
Data Scientist Intern

NOTEBOOK
credit_risk.ipynb